

พื้นฐานโปรแกรมภาษา R สำหรับการ วิเคราะห์ข้อมูล

ดร. ดำรง ไม้เรียง

dumrong.mai@biotec.or.th

ลง R และ Rstudio หรือยัง (Pre-requisite check)

- Install R

- ตัวโปรแกรมที่ทำงานจริง
- ต้องลงก่อนเสมอ

- Install Rstudio

- ลงหลังลง R แล้วเท่านั้น
- เป็นแค่โปรแกรมที่ช่วยในการเขียน code เท่านั้น
- ช่วยจัดระเบียบ และแสดงผล

เป้าหมาย


- **AI Writes, You Review**

- ไม่ต้องจำคำสั่ง ให้ AI เขียนตาม Prompt
- แต่เราต้องอ่านทบทวนสิ่งที่ AI เขียน ให้แน่ใจว่าจะให้ผลตามที่เรต้องการหรือไม่

- **Understand the Grammar**

- ต้องเข้าใจโครงสร้างภาษา R เบื้องต้น รวมทั้งลักษณะของตัวแปร และข้อมูล
- ถ้าเกิด Error ที่ทำให้ Code ที่เราเขียนทำงานไม่สำเร็จ ต้องแก้ไขได้ (Debug)
- ถ้าต้องการปรับแก้ผลลัพธ์จากการวิเคราะห์เล็กน้อย หรือปรับกราฟให้เป็นไปตามต้องการ ต้องแก้ไขได้

หน้าต่างของ RStudio



The screenshot displays the RStudio interface with the following components:

- Source Panel:** Contains R code for loading libraries and reading data. A green icon of a document with a play button is placed next to the code.
- Environment Panel:** Shows the 'Data' environment with a list of variables and their dimensions. A green icon of a database cylinder is placed next to the list.
- Console Panel:** Displays the output of the R script, including the message 'R is a collaborative project with many contributors.' and instructions on how to use 'demo()', 'help()', and 'help.start()'. A green icon of a terminal is placed next to the text.
- Files Panel:** Shows a file explorer view of the project directory, listing various CSV and XLSX files. A green icon of a folder is placed next to the list.

-  Source: พื้นที่เขียน Script (AI Code goes here)
-  Console: พื้นที่แสดงผลการรันคำสั่ง
-  Environment: ดูตัวแปรและข้อมูลที่โหลดไว้
-  Help/Plots: ดูความช่วยเหลือและกราฟ


จัดระเบียบด้วย R project

- เตรียม Folder สำหรับจัดเก็บงานที่เราจะเขียน
- Raw_Data = Folder สำหรับจัดเก็บข้อมูลดิบที่จะใช้ทำการวิเคราะห์ ควรเป็นข้อมูลที่จะไม่เข้าไปแก้ไขโดยตรงแล้ว
- Scripts = Folder สำหรับจัดเก็บ Code ที่เราจะเขียน
- Results = Folder สำหรับจัดเก็บผลจากการวิเคราะห์
- Plots = Folder สำหรับจัดเก็บรูป และกราฟที่สร้างขึ้น
- Optional เช่น Intermediate สำหรับจัดเก็บข้อมูลที่ถูกปรับแต่งด้วย Code ที่เราเขียนก่อนจะนำไปใช้ในขั้นต่อไป
- DEMO time!

Run scripts in Source Pane

Run a single line of the script


- Leave a cursor at a line
- Click  or
- Ctrl + Enter or
- Mac: Command + Enter



Run scripts in Source Pane

Run a part of the script

- Highlight the part
- Click  or
- Ctrl + Enter or
- Mac: Command + Enter




The screenshot shows the RStudio interface. The top pane, titled 'Untitled1*', contains a script with two lines: `1 1 + 1 + 2` and `2`. The first line is highlighted in blue. The bottom pane is split into a 'Console' and a 'Terminal' tab. The 'Console' tab is active and shows the output of the script execution: `> 1 + 1 + 2` followed by `[1] 4`, then `> 1 + 1 + 2` followed by `[1] 4`, then `> 1 + 2` followed by `[1] 3`, and finally a prompt `>` with a cursor. The 'Terminal' tab is also visible but empty.

Run scripts in Source Pane

Run all lines of the script

- Click the source pane
- Ctrl/Command + A
- Click  or
- Ctrl/Command + Enter



Useful keyboard shortcuts

- Ctrl + S = Save the script
- Ctrl + L = Clear the console pane
- Ctrl + Z =Undo and Ctrl + Y = Redo
- Ctrl + X =Cut, Ctrl + C = Copy, Ctrl + V =Paste
- Tab = ***Autofill***
- ↑ = ***Recall previously executed command***
- Ctrl + Shift + F10 = Restart R session
- Ctrl + Q = Quit R

More shortcuts: Tools → Keyboard Shortcuts Help

หลักการพื้นฐานแต่สำคัญในการเขียนโปรแกรมภาษา R

- Case sensitivity: ตัวใหญ่ตัวเล็กไม่เหมือนกัน `DATA1` $\neq$ `data1`
- Variable assignment: ใน R ใช้ได้ทั้ง “=” และ “<-” ให้ระวังเรื่องการเปรียบเทียบ เช่น `a` เท่ากับ `b` หรือไม่ ให้เขียนว่า `a == b` ไม่ใช่ `a = b`
- Comment: ในการเขียนโปรแกรม เราจะใส่ “#” หน้าบรรทัดที่ไม่ต้องการใช้ มีประโยชน์ในการเขียนอธิบายให้คนอื่นที่อ่าน Code เรา รวมทั้งตัวเราเองที่มาอ่านในอนาคต รวมทั้งใช้ปิดบางบรรทัดชั่วคราวได้
- Variable versus String: เราสามารถเก็บข้อมูลข้อความได้ แต่ต้องเขียนในเครื่องหมายคำพูดเท่านั้น คือ “ ” หรือ ‘ ’ ไม่อย่างนั้นข้อความจะถูกเข้าใจว่าเป็นตัวแปรแทน

ประเภทของข้อมูลพื้นฐาน

Numeric: ตัวเลข สามารถใช้คำนวณได้


Character: ตัวหนังสือ

Logic: ค่าตรรกศาสตร์ จริง (True) หรือ เท็จ (False)

ภาษาสำหรับบรรจุข้อมูล

Vector: column ที่ใช้บรรจุข้อมูลประเภทเดียวกันเท่านั้น

Data frame: ตารางที่แต่ละ column คือ Vector แต่สมาชิกใน Vector เชื่อมโยงกันโดยตำแหน่งคือ Row



การใช้ Data frame

- `print()` พิมพ์ Data frame ใน Console เพื่อดูข้อมูลเร็ว ๆ ไม่เหมาะกับ Data frame ขนาดใหญ่
- `head()/tail()` พิมพ์ Data frame ใน Console เฉพาะ Row แรก ๆ หรือ Row ท้าย
- `View()` ดู Data frame ใน Rstudio สามารถ sort และเลื่อนดูข้อมูลได้ แต่ Data frame ขนาดใหญ่ ก็จะถูก
- `dim()` ดูจำนวน Row และ Column
- `str()` ดูข้อมูลสรุปของ Data frame

การใช้ Data frame

- การใช้ “\$” เพื่อเข้าถึง Column ที่ต้องการ
- การใช้ “[]” เพื่อเข้าถึง Row, Column หรือ Cell ที่ต้องการ

การใช้ [] ในการเข้าถึงข้อมูลใน Data frame และ Matrix

- `df[,1]` = Column ที่หนึ่ง
- `df[,“name”]` = Column “name”
- `df[1, ]` = Row ที่ 1
- `df[[“name”]]` = Column “name”
- `df[1,1]` = Cell จาก Column ที่หนึ่ง และ Row ที่ 1

การใช้ [] ในการเข้าถึงข้อมูลใน Data frame และ Matrix

- `df[1:3 ,5:7]` = Row ที่ 1 ถึง 3 และ Column ที่ 5 ถึง 7
- `df[ which(df$name == “สมชาย”), ]` = เลือกแถวที่มี name (ชื่อ) เป็นสมชาย โดยแสดงทุก Column
- `df %>% filter(name == “สมชาย”)` = เลือกแถวที่มี name (ชื่อ) เป็นสมชาย โดยแสดงทุก Column โดยใช้ผ่าน Package “tidyverse”

การใช้ Function ใน R

- ใช้ในกรณีจะทำอะไรซ้ำ ๆ แค่เปลี่ยน Inputs
- ```
myfunc <- function(input){
 output <- do_something(input)
 return(output)
}
```

# HELP!!!

- ?mean = หา Documentation ของคำสั่งที่พร้อมใช้งาน
- ??glm = หา Documentation ของคำสั่งที่พร้อมใช้งาน รวมทั้งคำสั่งที่มีชื่อคล้ายกันที่อยู่ใน Package ที่ยังไม่ได้ถูกเรียกใช้

# Packages

- คำสั่งบางอย่างเฉพาะเจาะจงเกินไป ไม่จำเป็นต้องใช้ตลอดเวลา
- ติดตั้งแยกต่างหากตามงานที่จะใช้ และเรียกมาใช้เมื่อต้องการจริง ๆ
- `install.package("something", dep = True)`
- `library(something)`

# Bioconductor Packages

- คำสั่งเฉพาะงานทางชีววิทยา และชีวสารสนเทศ
- ใช้คำสั่งพิเศษในการติดตั้ง เนื่องจาก Package เก็บไว้คนละที่ (CRAN versus Bioconductor)
- `install.packages("BiocManager")`
- `BiocManager::install("something")`
- `library(something)`

## Working directories

- เราต้องรู้ว่กำลังทำงานที่ไหนในเครื่องของเรา เพราะจะต้องเรียกใช้ File ข้อมูลจากตำแหน่งที่ถูกต้อง และรู้ว่าเมื่อสั่ง Save เก็บผลการวิเคราะห์ หรือกราฟต่าง ๆ File นั้นอยู่ที่ไหน
- `getwd()` #ตรวจสอบว่าทำงานอยู่ที่ Directory ไหน
- `setwd()` #ย้าย Working directory
- สามารถใช้ Tab ในการเติม/เดา directory และ sub-directory ไปยัง File หรือ Folder ที่ต้องการได้

# การนำเข้าข้อมูลจาก File

- R สามารถนำเข้าข้อมูลจาก File ต่างๆ เช่น
  - 1) Text files เช่น \*.csv \*.tab \*.txt แนะนำให้เก็บข้อมูลใน File ประเภทนี้เพราะจะได้โดน Auto-format
  - 2) Excel file (\*.xls \*.xlsx) เป็น File ที่ถูกใช้เก็บข้อมูลบ่อย ๆ ให้ระวังในการใช้งาน เนื่องจาก Excel ชอบ Auto-format ข้อมูล ทำให้เปลี่ยนได้โดยเฉพาะข้อมูลวันที่ และอาจจะต้อง Format ข้อมูลเองก่อน เช่น Merged cells บนหัวตาราง
  - 3) อื่น ๆ เช่น ข้อมูลจากโปรแกรมสถิติ อื่น ๆ เช่น SPSS, SAS และ STATA
- สามารถใช้ UI ใน Rstudio ในการนำเข้าข้อมูล แต่ควรเก็บ Auto-generate code ไว้ใน Script ที่ใช้งานด้วย

## การเก็บข้อมูลจากการวิเคราะห์

- R สามารถบันทึกข้อมูลจากการวิเคราะห์เป็น File ประเภทต่างๆ เช่น
  - 1) Text files เช่น \*.csv \*.tab \*.txt แนะนำให้เก็บข้อมูลใน File ประเภทนี้เพราะจะไม่ได้โดน Auto-format
  - 2) Excel file (\*.xls \*.xlsx) ไม่แนะนำ เนื่องจากข้อมูลอาจจะโดน Auto-format ให้ Save เป็น Text files (\*.csv \*.tab \*.txt ) ก่อนแปลงเป็น Excel อีกที

# Bugs ของมือใหม่

- Comma หายหรือเกิน
- “ ” และ ‘ ’ หายหรือเกิน
- วงเล็บไม่ครบ หรือ เกิน
- object not found อาจเกิดจาก
  - 1) Case ผิด
  - 2) สะกดผิด
  - 3) ลืม “ ” หรือ ‘ ’



## แบบฝึกหัด

- AI จะเขียน Code ให้ แต่มีโอกาที่ Code จะมีข้อผิดพลาด
- วัตถุประสงค์ แก่ Code เพื่อให้ Code ทำงานได้